

Reporte Técnico: Práctica 2.3

Técnicas de Modelado I

Roberto Misael Reyes Cruz

Boleta: 2021301999

17 de abril de 2026

1. Introducción

El presente reporte detalla la resolución de la Práctica 2.3 de la asignatura de Minería de Datos, enfocada en **Técnicas de Modelado I**. El objetivo principal es aplicar y comprender algoritmos fundamentales de la minería de datos: **Correlación de Pearson**, **Clasificador Naïve Bayes** y **Reglas de Asociación (Apriori)**.

Se ha utilizado el dataset **Telco Customer Churn**, un conjunto de datos estándar en la industria de las telecomunicaciones para predecir la fuga de clientes. Este dataset contiene información demográfica, servicios contratados y el estado de abandono (*Churn*). El número de boleta proporcionado, **2021301999**, se ha utilizado para establecer la semilla (`random.state=1999`) en los procesos de muestreo, asegurando la reproducibilidad de los resultados.

2. Marco Teórico

2.1. Correlación de Pearson

Mide la relación lineal entre dos variables numéricas. Un valor cercano a 1 indica una fuerte correlación positiva, -1 una fuerte correlación negativa, y 0 ausencia de relación lineal. Es vital identificar la multicolinealidad, ya que variables altamente correlacionadas pueden inflar artificialmente las probabilidades en modelos bayesianos.

2.2. Teorema de Bayes

El **Clasificador Naïve Bayes** es un algoritmo probabilístico basado en el Teorema de Bayes, que asume una independencia condicional entre las características. El teorema se expresa como:

$$P(C|X) = \frac{P(X|C) \cdot P(C)}{P(X)} \quad (1)$$

Donde $P(C|X)$ es la probabilidad posterior de la clase C dado el predictor X .

2.3. Métricas de Reglas de Asociación

- **Soporte:** Frecuencia con la que aparecen los ítems en el conjunto de datos.
- **Confianza:** Probabilidad de que el consecuente ocurra dado que el antecedente ya ocurrió.
- **Lift:** Evalúa la fuerza de una regla en comparación con la ocurrencia aleatoria. Un $Lift > 1$ indica asociación positiva; $Lift < 1$ asociación negativa; y $Lift = 1$ independencia.

3. Desarrollo

3.1. Análisis de la Matriz de Correlación

Se calculó la matriz de correlación para las variables numéricas. Se identificó una alta correlación entre **tenure** (antigüedad) y **TotalCharges** (cargos totales), con un valor de **0.8258**.

- **Variable eliminada:** TotalCharges.
- **Razón:** Para evitar la multicolinealidad. Dado que los cargos totales son una función directa de la antigüedad y los cargos mensuales, mantener ambas violaría la suposición de independencia de Naïve Bayes.

3.2. Reglas de Asociación Engañosas

Se filtraron las reglas con **Alta Confianza** ($> 0,8$) y **Lift Bajo** ($\leq 1,05$).

Tabla 1: Reglas identificadas con la trampa del Lift.

Antecedente	Consecuente	Soporte	Confianza	Lift
{OnlineSecurity_No}	{PhoneService_Yes}	0.4405	0.8859	0.9807
{OnlineBackup_No}	{PhoneService_Yes}	0.3829	0.8723	0.9657
{DeviceProtection_No}	{PhoneService_Yes}	0.3863	0.8781	0.9721

Explicación de negocio: Estas reglas son engañosas porque el servicio telefónico es extremadamente común ($> 90\%$). El Lift cercano a 1 indica que el antecedente no influye realmente en el consecuente; es una coincidencia estadística por la alta frecuencia de PhoneService_Yes.

3.3. Cálculos Manuales (Muestra Boleta: 2021301999)

3.3.1. Tabla

Tabla 2: Muestra de 10 registros del dataset Telco Customer Churn (Muestra Boleta: 2021301999)

@llcccrclllllllllr.c@																	
ID	Gen.	SC	Part.	Dep.	Ten.	PS	ML	IS	OS	OB	DP	TS	STV	SM	Cont.	MC	Ch.
9357-UJRUN	Male	0	Yes	No	24	Yes	Yes	DSL	Yes	No	No	Yes	No	No	1yr	58.35	No
4730-AWNAU	Male	0	Yes	Yes	36	No	NPS	DSL	Yes	No	Yes	Yes	Yes	Yes	1yr	60.70	No
9867-NNXLC	Female	0	No	No	22	Yes	No	No	NIS	NIS	NIS	NIS	NIS	NIS	MTM	20.05	No
3243-ZHOHY	Female	0	No	No	16	Yes	No	No	NIS	NIS	NIS	NIS	NIS	NIS	1yr	20.10	No
0384-RVBPI	Male	0	No	No	20	Yes	No	DSL	Yes	No	Yes	No	No	Yes	MTM	64.40	No
3709-OLJEA	Male	0	No	No	26	Yes	No	FO	No	Yes	Yes	Yes	No	No	1yr	85.20	No
5118-MUEYH	Female	0	Yes	No	48	Yes	Yes	FO	No	Yes	No	Yes	Yes	Yes	MTM	105.1	No
5501-TVMGM	Male	0	No	No	1	Yes	No	DSL	No	No	No	No	No	Yes	MTM	55.25	No
7271-AJDTL	Female	0	Yes	No	55	Yes	Yes	FO	No	Yes	Yes	No	Yes	No	MTM	94.45	No
9054-FOWNV	Male	0	Yes	Yes	22	Yes	Yes	FO	No	No	Yes	No	Yes	No	MTM	88.75	No

Abreviaturas: **SC:** SeniorCitizen, **PS:** PhoneService, **ML:** MultipleLines, **IS:** InternetService, **OS:** OnlineSecurity, **OB:** OnlineBackup, **DP:** DeviceProtection, **TS:** TechSupport, **STV:** StreamingTV, **SM:** StreamingMovies, **Cont:** Contract (1yr: One year, MTM: Month-to-month), **MC:** MonthlyCharges, **Ch:** Churn, **NPS:** No phone service, **NIS:** No internet service, **FO:** Fiber optic.




Figura 1: Cálculo manual del Teorema de Bayes para el registro 9357-UJRUN.




Figura 2: Retículo de itemsets con poda por soporte insuficiente ($\geq 30\%$).

Item (Servicio)	Conteo (Frecuencia)	Soporte (Cont/10)
OS	3	0.30
O B	3	0.30
T S	3	0.30
1) P	4	0.40
STV	3	0.30
S M	3	0.30
M L	5	0.50

Figura 3: Retículo de itemsets con poda por soporte insuficiente ($\geq 30\%$).

4. Conclusiones

El uso de algoritmos de “caja negra” sin auditar sus suposiciones es peligroso. La **multicolinealidad** puede sesgar el modelo, mientras que la **trampa del Lift** demuestra que la confianza no siempre implica utilidad de negocio. Auditar modelos manualmente valida la lógica frente a la estadística pura.

5. Referencias

- IBM. (2024). *Telco Customer Churn Dataset*. Recuperado de GitHub.
- Raschka, S. (2024). *mlxtend: Machine Learning Library Extensions*.
- Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*.