

Reporte Técnico: Exploración de Datos y Cubos OLAP

Práctica 1.1 - Ingeniería en Inteligencia Artificial

Roberto Misael Reyes Cruz

26 de febrero de 2026

1. Introducción y Marco Teórico

En la fase de **Comprensión de los Datos**, es vital explorar la información desde múltiples perspectivas para encontrar patrones descriptivos. Para lograr esto, se utiliza un modelo de datos multidimensional conocido como **Cubo de Datos**.

Un cubo permite modelar datos en múltiples dimensiones simultáneamente, compuesto por:

- **Dimensiones:** Atributos categóricos que representan perspectivas de análisis (ej. Tiempo, Clase).
- **Medidas (Hechos):** Valores numéricas agregados (ej. Suma de montos).
- **Operaciones OLAP:** Técnicas como *Slice* (rebanar para filtrar una dimensión) y *Roll-up* (agrupar para reducir el detalle) que permiten navegar por los datos para “entender el pasado”.

2. Desarrollo (Metodología CRISP-DM)

2.1. Fase 1 y 2: Comprensión del Negocio y de los Datos

- **Objetivo:** Identificar patrones de comportamiento en fraudes bancarios históricos mediante segmentación horaria y de montos.
- **Dataset:** Credit Card Fraud Detection (Kaggle).
- **Transformaciones:** Dado que el dataset es mayormente numérico (PCA), se crearon dimensiones interpretables:
 - **Medida:** `Amount` (Importe de la transacción).
 - **Dimensiones:** `Class` (Fraude/Legítima), `Time_Bin` (Madrugada, Mañana, Tarde, Noche) y `Amount_Range` (Bajo, Medio, Alto).

2.2. Fase 3 y 4: Construcción del Cubo y Operaciones

A continuación se presenta la implementación en Python utilizando la biblioteca `pandas`:

```
1 import pandas as pd
2 import numpy as np
3
4 # Carga y Transformación
5 df = pd.read_csv('creditcard.csv')
6 df['Hora'] = (df['Time'] // 3600) % 24
7 df['Time_Bin'] = pd.cut(df['Hora'], bins=[0, 6, 12, 18, 24],
8                          labels=['Madrugada', 'Mañana', 'Tarde', 'Noche'],
9                          include_lowest=True)
10 df['Amount_Range'] = pd.cut(df['Amount'], bins=[0, 50, 500, df['Amount'].
11                             max()],
12                             labels=['Bajo', 'Medio', 'Alto'],
13                             include_lowest=True)
14 # Construcción del Cubo (Suma)
15 cubo = pd.pivot_table(df, values='Amount', index=['Class', 'Time_Bin'],
16                        columns=['Amount_Range'], aggfunc=np.sum, fill_value=
17                        =0)
18 # Operación SLICE: Solo Fraudes
19 slice_fraude = cubo.loc[1]
20 # Operación ROLL-UP: Total por Clase
21 rollup_resultado = df.groupby('Class')['Amount'].sum()
```

Listing 1: Construcción de Cubo OLAP y Operaciones

3. Análisis de Resultados (Preguntas Guía)

1. ¿Por qué OLAP es minería descriptiva y no predictiva?

Porque las operaciones OLAP se basan en la agregación y resumen de datos históricos. Su propósito es organizar lo que ya sucedió en dimensiones comprensibles. No utiliza algoritmos de aprendizaje para estimar valores futuros, sino que se limita a describir patrones existentes en la base de datos.

2. Patrón o hallazgo detectado:

Al aplicar un *Slice* sobre la clase de Fraude, se observó una anomalía: existe un vacío absoluto de transacciones "Grandes" durante la **Noche** (0,00). Asimismo, mediante el análisis de **Promedio**, se detectó que los fraudes de rango "Medio" en la tarde son más agresivos (promedio de 205,49) que las transacciones normales (154,34).

3. Ayuda a la "Preparación de los Datos" en CRISP-DM:

La construcción del cubo reveló un desbalance crítico de clases. Esto informa que, en la siguiente fase de CRISP-DM, es obligatorio aplicar técnicas de balanceo (como SMO-TE) y confirma que la **Franja Horaria** es un predictor valioso que debe ser incluido en el modelo final.

4. Conclusiones y Referencias

Conclusiones

La práctica demostró que las herramientas OLAP son fundamentales para la auditoría y comprensión de datos complejos. Transformar variables continuas en dimensiones categóricas permitió identificar que el fraude tiene "horariosz rangos" preferidos, facilitando la toma de decisiones técnicas para las siguientes fases del proyecto de IA.

Referencias

- Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.
- Chapman, P. et al. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*.
- Machine Learning Group - ULB. (2018). *Credit Card Fraud Detection Dataset*. Kaggle.