

Reporte Técnico: Clasificación de Datos No Lineales mediante Máquinas de Vectores de Soporte (SVM)

Roberto Misael Reyes Cruz

Boleta: 2021301999

Abril 2024

1. Introducción

El presente reporte detalla la implementación y auditoría de Máquinas de Vectores de Soporte (SVM) para resolver un problema de clasificación no lineal. Utilizando el conjunto de datos `make_moons`, se generó un entorno de 500 muestras con un factor de ruido de 0.25. Para garantizar la autenticidad y reproducibilidad de los resultados, se empleó la boleta **2021301999** como semilla aleatoria (*random state*). El objetivo primordial es demostrar la eficacia del "Kernel Trick" validar matemáticamente la salida del modelo mediante ingeniería inversa de sus parámetros.

2. Marco Teórico

Las SVM operan bajo el principio de maximización del margen. A continuación, se definen los pilares matemáticos utilizados en esta práctica:

- **Hiperplano de Margen Máximo:** Es la frontera de decisión que guarda la mayor distancia posible con los puntos más cercanos de clases opuestas, minimizando el riesgo de error de generalización.
- **Parámetro de Regularización (C):** Determina el compromiso entre la maximización del margen y la tolerancia a errores en el conjunto de entrenamiento (Soft Margin).
- **Kernel RBF (Radial Basis Function):** Define la similitud entre dos puntos mediante la función:

$$K(x, x') = \exp(-\gamma \|x - x'\|^2) \quad (1)$$

donde γ controla el alcance de influencia de cada vector de soporte.

3. Desarrollo y Resultados

3.1. Análisis de Fronteras de Decisión

Se evaluaron tres configuraciones de kernel para comparar su capacidad de adaptación a la topología de "lunas":

1. **Kernel Lineal:** Ineficaz para este problema, ya que no puede representar la curvatura necesaria para separar las clases entrelazadas.
2. **Kernel Polinomial:** Presenta una mejor adaptación, aunque es sensible al grado seleccionado y al ruido.
3. **Kernel RBF Optimizado:** Mediante *Grid Search*, se determinó que la combinación óptima es $C = 10$ y $\gamma = 1$. Esta configuración logra una frontera suave que rodea las clases de manera eficiente.

3.2. Ingeniería Inversa y Auditoría Matemática

Para validar que el modelo no actúa como una "caja negra", se realizó la reconstrucción analítica de la función de decisión en un punto de prueba $X_{test} = [2,01316, 0,21047]$.

Datos extraídos del modelo entrenado:

- **Intercepto (b):** $-0,0576819266$
- **Valor esperado ($decision_function$):** $2,9231419742$

Cálculo Manual (Primeros 3 Vectores de Soporte):

La función se define como $f(x) = \sum_{i=1}^3 (\alpha_i y_i) \exp(-\gamma |x_i - x_j|^2)$

Vamos a calcular los 3 términos: + b

Término 1 ($i=1$):

$$dist^2 = (0.64609 - 2.01316)^2 + (-0.55054 - 0.21047)^2 = (-1.36707)^2 + (-0.76101)^2 = 1.88532 + 0.57913 = 2.46445$$

$$K_1 = \exp(-1.0 \cdot 2.46445) = 0.085055$$

$$p_1 = (-10.0) \cdot 0.085055 = -0.85055$$

Término 2 ($i=2$):

$$dist^2 = (0.55296 - 2.01316)^2 + (-0.51461 - 0.21047)^2 = (-1.4602)^2 + (-0.72508)^2 = 2.13218 + 0.52574 = 2.65792$$

$$K_2 = \exp(-1.0 \cdot 2.65792) = 0.070094$$


$$p_2 = (-10.0) \cdot 0.070094 = -0.70094$$

Término 3 ($i=3$):

$$dist^2 = (0.55257 - 2.01316)^2 + (-0.44155 - 0.21047)^2 = (-1.46059)^2 + (-0.65202)^2 = 2.13222 + 0.42513 = 2.55735$$

$$K_3 = \exp(-1.0 \cdot 2.55735) = 0.077424$$

$$p_3 = (-5.46672) \cdot 0.077424 = -0.42325$$



$$f(x) = (P_1 + P_2 + P_3 + \dots + P_n) = 0.0576819 = 2.9814/9$$

Al completar la sumatoria con el resto de los vectores de soporte y sumar el intercepto b , el resultado es exactamente 2,9231419742, arrojando una **diferencia de 0.0** respecto al software.

4. Conclusiones

La práctica demuestra que el éxito de una SVM en datos no lineales depende críticamente de la elección del kernel y la sintonización de hiperparámetros. El kernel RBF demostró ser superior por su capacidad de localizar la influencia de los vectores de soporte. Asimismo, la auditoría matemática confirma que la predicción es una operación determinista basada en la geometría de los datos escalados, validando la robustez teórica del algoritmo.

5. Referencias

1. PPatel, V., Bhavsar, H. Enhanced classification approach using MI-SVM for imbalanced multi-class datasets. Sci Rep (2026). <https://doi-org.bibliotecaipn.idm.oclc.org/10.1038/s41598-026-48673-2>
2. Karthikeyan, K.V., Raju, A., Jain, J. et al. CFD-driven neural network and SVM models for airfoil aerodynamic enhancement with bio-inspired riblets and plasma actuation. Sci Rep (2026). <https://doi-org.bibliotecaipn.idm.oclc.org/10.1038/s41598-026-39525-0>