

Curso: Minería de Datos

Ingeniería en Inteligencia Artificial

Presentación del Curso

Instituto Politécnico Nacional

Daniel Sánchez Ruiz

Crterios de Evaluación

La calificación final se compondrá de la siguiente manera para los primeros parciales:

- **30 % Participaciones:** Intervenciones en clase y actividades rápidas.
- **30 % Prácticas:** Ejercicios de laboratorio y reportes técnicos.
- **40 % Examen:** Evaluación teórica de los conceptos vistos.

Nota Importante: Último Parcial

En el último parcial **NO habrá examen**. El 40 % correspondiente se evaluará mediante un **Proyecto Final** integrador.

Reglas del Juego (Políticas del Curso)

Para mantener el orden y la justicia en la evaluación, se aplicarán estrictamente las siguientes reglas:

- 1 Cero Tolerancia a Retrasos:** No se aceptan trabajos, prácticas o proyectos fuera de la fecha y hora establecida.
- 2 Defensa Personal de Prácticas:** Si una práctica se entrega pero el alumno no está presente para defenderla o explicarla personalmente, **no se tomará en cuenta** (calificación de 0).
- 3 Defensa del Proyecto Final:** Aplica la misma regla; si no se presenta el proyecto de forma personal, la calificación será anulada automáticamente.

Unidad I: El proceso de minado de datos

Objetivo: Comprender el flujo de trabajo y la justificación de la minería de datos.

- **1.1 Contextualización:** ¿Por qué minería de datos? La era de la información y la falta de conocimiento útil [1][2].
- **1.2 Tipos de problemas:**
 - Descriptivos (Asociación, Clustering) [3][4].
 - Predictivos (Clasificación, Regresión) [5][6].
- **1.3 Metodologías Estándar:**
 - SEMMA (SAS Institute) [7].
 - CRISP-DM (Cross-Industry Standard Process for Data Mining) [8][9].
- **1.4 Evaluación del proceso:** Entrenamiento, prueba y validación cruzada [10].

Unidad II: Preprocesamiento de datos

Objetivo: Aprender a limpiar y preparar los datos (el 80 % del trabajo real).

- **2.1 Calidad de datos:** Ruido, valores atípicos (outliers) y valores faltantes [11][12].
- **2.2 Tipos de datos:** Manejo de atributos categóricos y numéricos [13].
- **2.3 Fuentes y Selección:** Sensores, bases de datos y archivos planos. Integración de datos [14].
- **2.4 Salida del proceso:** Entendimiento de modelos lineales, árboles y reglas.
- **2.5 Transformación:**
 - Limpieza y conversión.
 - Reducción de dimensionalidad (PCA, Selección de atributos) [15][16].

Unidad III: Técnicas de minería de datos

Objetivo: Aplicar algoritmos para descubrir patrones.

- **3.1 Métodos estadísticos:** Correlación y análisis básico [17].
- **3.2 Reglas de asociación:** Algoritmo Apriori, Soporte y Confianza (Market Basket Analysis) [18][19].
- **3.3 Árboles de decisión:** Algoritmos ID3, C4.5, Ganancia de información y Poda [20][21].
- **3.4 Redes neuronales:** Perceptrón, Backpropagation y una introducción al Deep Learning [22][23].
- **3.5 Minería de textos:** Procesamiento de lenguaje natural (NLP) para datos no estructurados [24][25].

Unidad IV: Plataformas de Minería

Objetivo: Dominar herramientas comerciales y Open Source.

- **4.1 Matlab:** Herramientas de IA y estadística.
- **4.2 SAS Enterprise Miner:** Funcionalidades, flujo de trabajo y costos [26][27].
- **4.3 WEKA:** Uso de software Open Source para clasificación y clustering [28][29].
- **4.4 Rapidminer:** Diseño de flujos de trabajo visuales [30].

Cierre: Integración de conocimientos y Proyecto Final.

Actividad: "Cluster Humano"

Instrucciones:

- 1 Todos deben ponerse de pie.
- 2 Yo diré una característica (variable). Ustedes deben agruparse físicamente con quienes compartan esa característica.
- 3 **Variables a iterar:**
 - "Mes de nacimiento" (12 clusters potenciales).

Actividad: "Cluster Humano"

Instrucciones:

- 1 Todos deben ponerse de pie.
- 2 Yo diré una característica (variable). Ustedes deben agruparse físicamente con quienes compartan esa característica.
- 3 **Variables a iterar:**
 - "Mes de nacimiento" (12 clusters potenciales).
 - "Preferencia: ¿Perros o Gatos?" (2 clusters grandes).

Actividad: "Cluster Humano"

Instrucciones:

- 1 Todos deben ponerse de pie.
- 2 Yo diré una característica (variable). Ustedes deben agruparse físicamente con quienes compartan esa característica.
- 3 **Variables a iterar:**
 - "Mes de nacimiento" (12 clusters potenciales).
 - "Preferencia: ¿Perros o Gatos?" (2 clusters grandes).
 - "Distancia de traslado a la escuela: ¿30min, 30-60min, ¿1hr".

Actividad: "Cluster Humano"

Instrucciones:

- 1 Todos deben ponerse de pie.
- 2 Yo diré una característica (variable). Ustedes deben agruparse físicamente con quienes compartan esa característica.
- 3 **Variables a iterar:**
 - "Mes de nacimiento" (12 clusters potenciales).
 - "Preferencia: ¿Perros o Gatos?" (2 clusters grandes).
 - "Distancia de traslado a la escuela: ¿30min, 30-60min, ¿1hr".
- 4 Observen cómo los grupos cambian de tamaño y forma según la variable elegida. ¡Eso es minería de datos!

Examen Diagnóstico

Instrucciones: Responde brevemente en una hoja. No afecta tu calificación, es para medir el nivel del grupo.

- 1 Define con tus propias palabras qué es "Minería de Datos".
- 2 ¿Cuál es la diferencia entre datos estructurados y no estructurados?
- 3 Menciona una metodología de desarrollo de software o de ciencia de datos que conozcas (ej. Cascada, Agile, CRISP-DM).
- 4 ¿Qué entiendes por "limpieza de datos" por qué crees que es necesaria?
- 5 Explica la diferencia entre un problema de Clasificación y uno de Clustering (Agrupamiento).
- 6 ¿Qué es una regresión lineal?
- 7 ¿Has utilizado alguna vez el lenguaje SQL? ¿Para qué?
- 8 ¿Qué es un "falso positivo" en el contexto de una prueba o predicción?
- 9 Menciona 3 lenguajes de programación o herramientas de software que sirvan para analizar datos.
- 10 ¿Qué significan las siglas IA (Inteligencia Artificial)?

Bibliografía Básica del Curso

- Han, J., Pei, J., & Tong, H. (2022). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.
- Larose, D. T., & Larose, C. D. (2015). *Data Mining and Predictive Analytics*. Wiley.
- Zong, C., Xia, R., & Zhang, J. (2021). *Text Data Mining*. Springer.
- Hodeghatta, U. R., & Nayak, U. (2023). *Practical Business Analytics Using R and Python*. Apress.
- Programa de Estudios: Ingeniería en Inteligencia Artificial (Minería de Datos). Instituto Politécnico Nacional.