

Técnicas de Minería de Datos

Métodos Estadísticos y Reglas de Asociación

Ingeniería en Inteligencia Artificial

Instituto Politécnico Nacional

Daniel Sánchez Ruiz

Agenda de la Sesión

- 1 3.1 Métodos Estadísticos
- 2 3.2 Reglas de Asociación
- 3 Cierre y Referencias

Unidad III: Técnicas de Minería de Datos

Habiendo superado la fase de Preparación de Datos (Unidad II), entramos a la fase central de la metodología CRISP-DM: el **Modelado**.

En esta unidad exploraremos los algoritmos puros que extraen el conocimiento oculto. Comenzaremos con dos enfoques fundamentales:

- ➊ **Métodos Estadísticos:** Uso de la teoría de la probabilidad y la varianza para predecir clases y descubrir relaciones (ej. Correlación de Pearson, Clasificador Naïve Bayes).
- ➋ **Reglas de Asociación:** Enfoque descriptivo para descubrir elementos que co-ocurren frecuentemente en bases de datos transaccionales.

3.1 Métodos Estadísticos: Correlación

El análisis de covarianza y correlación es el primer método estadístico para descubrir redundancia y dependencia entre atributos numéricos continuos.


Coeficiente de Correlación de Pearson (r)

Mide la fuerza y dirección de la relación **lineal** entre dos variables. Su rango es $-1 \leq r \leq 1$.

$$r_{x,y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

- $r > 0$: Relación positiva (Ambas crecen).
- $r < 0$: Relación negativa (Una crece, la otra decrece).
- $r \approx 0$: Ausencia de relación lineal.

Representación Visual de la Correlación



Previo a modelar, la correlación nos permite descartar variables redundantes (multicolinealidad) [6].

Modelado Estadístico: Clasificador Naïve Bayes

En tareas de predicción y clasificación, el enfoque estadístico más puro es el basado en el **Teorema de Bayes**.

En lugar de calcular distancias, calcula la **probabilidad de pertenencia a una clase** dada la evidencia de los atributos.

Teorema de Bayes

$$P(H|E) = \frac{P(E|H) \cdot P(H)}{P(E)}$$

- $P(H)$: Probabilidad a priori (Frecuencia base de la clase).
- $P(E|H)$: Verosimilitud (Likelihood) de observar la evidencia E en la clase H .
- $P(H|E)$: **Probabilidad a posteriori** (Lo que queremos predecir).

¿Por qué se llama "Naïve"(Ingenuo)?

En la vida real, los atributos predictivos suelen estar correlacionados. Sin embargo, para que las matemáticas sean computacionalmente viables en bases de datos enormes, el algoritmo asume **Independencia Condicional** entre los atributos.

Es decir, asume "ingenuamente" que la presencia del atributo A_1 no afecta en absoluto la probabilidad de observar el atributo A_2 .

Bajo esta asunción, la ecuación se simplifica a la multiplicación directa de probabilidades individuales:

$$P(E|H) = P(A_1|H) \times P(A_2|H) \times \cdots \times P(A_n|H)$$

Ejemplo Naïve Bayes (1/3)

Problema: Queremos predecir si un cliente comprará una computadora ($Clase = Si$) basándonos en su Edad y su Ingreso.

Base de Conocimiento (10 registros):

- Total de clientes que compraron (Si): 6.
- Total de clientes que NO compraron (No): 4.

Distribución de atributos dados los que Compraron (Si):

- Edad ≤ 30 : 2 Edad > 30 : 4
- Ingreso Alto: 3 Ingreso Bajo: 3

Distribución de atributos dados los que NO Compraron (No):

- Edad ≤ 30 : 3 Edad > 30 : 1
- Ingreso Alto: 1 Ingreso Bajo: 3

Ejemplo Naïve Bayes (2/3)

Nuevo Cliente a Predecir: Edad ≤ 30 (E_1), Ingreso = Alto (E_2).

Paso 1: Probabilidades a Priori $P(H)$

- $P(Si) = 6/10 = 0,6$
- $P(No) = 4/10 = 0,4$

Paso 2: Cálculo de la Verosimilitud conjunta $P(E|H)$

- Para la clase Si : $P(E|Si) = P(E_1|Si) \times P(E_2|Si) = (2/6) \times (3/6) = 0,333 \times 0,5 = 0,166$
- Para la clase No : $P(E|No) = P(E_1|No) \times P(E_2|No) = (3/4) \times (1/4) = 0,75 \times 0,25 = 0,187$

Ejemplo Naïve Bayes (3/3)

Paso 3: Calcular la Probabilidad a Posteriori (Numerador de Bayes) Multiplicamos la verosimilitud por la probabilidad a priori para cada clase:

- Probabilidad Cruda de *Si*: $P(E|Si) \times P(Si) = 0,166 \times 0,6 = \mathbf{0,0996}$
- Probabilidad Cruda de *No*: $P(E|No) \times P(No) = 0,187 \times 0,4 = \mathbf{0,0748}$

Conclusión: Dado que $0,0996 > 0,0748$, el clasificador estadístico Naïve Bayes predice que el cliente **SÍ** comprará la computadora.

Nota: Las probabilidades no suman 1 porque omitimos dividir entre $P(E)$ por ser una constante común en ambas clases.

Ejercicio 1: Clasificación con Naïve Bayes

Problema Clínico: Detectar si un tumor es maligno (M) o benigno (B).

Datos Globales ($N = 10$): 7 tumores benignos (B), 3 tumores malignos (M).

Evidencias Clínicas (Tamaño y Forma):

- De los 7 Benignos: 6 son Pequeños, 1 es Grande. 5 son Ovalados, 2 son Irregulares.
- De los 3 Malignos: 1 es Pequeño, 2 son Grandes. 0 son Ovalados, 3 son Irregulares.

Llega un nuevo paciente con un tumor **Pequeño e Irregular**. Utilizando Naïve Bayes, ¿Cómo lo clasifica el algoritmo y cuáles son los dos valores matemáticos (probabilidades crudas) que comparaste?

Solución al Ejercicio 1

Nuevo Paciente = {Pequeño, Irregular}

1. **Probabilidades a Priori:** $P(B) = 0,7$, $P(M) = 0,3$.

2. **Probabilidades Condicionales para Clase Benigno (B):**

- $P(\text{Pequeño} | B) = 6/7 \approx 0,857$
- $P(\text{Irregular} | B) = 2/7 \approx 0,285$

3. **Probabilidades Condicionales para Clase Maligno (M):**

- $P(\text{Pequeño} | M) = 1/3 \approx 0,333$
- $P(\text{Irregular} | M) = 3/3 = 1,0$

4. **Cálculo de Probabilidades a Posteriori Crudas:**

- Score Benigno: $P(B) \times P(\text{Pequeño} | B) \times P(\text{Irregular} | B) = 0,7 \times 0,857 \times 0,285 = \mathbf{0,171}$
- Score Maligno: $P(M) \times P(\text{Pequeño} | M) \times P(\text{Irregular} | M) = 0,3 \times 0,333 \times 1,0 = \mathbf{0,0999}$

Respuesta: Dado que $0,171 > 0,0999$, el modelo lo clasifica como **Benigno**.

3.2 Reglas de Asociación: Análisis Descriptivo

A diferencia de la predicción clásica, las **Reglas de Asociación** (o *Market Basket Analysis*) buscan descubrir patrones y co-ocurrencias fuertes entre elementos en grandes conjuntos de datos transaccionales.


Estructura Fundamental

Una regla de asociación tiene la forma lógica $A \rightarrow B$, donde A es el antecedente y B es el consecuente.
Interpretación: "Si un cliente compra A , entonces es probable que también compre B ".

Su aplicación va desde el diseño de supermercados (colocar la cerveza junto a los pañales), hasta sistemas de recomendación en Netflix y Amazon.

Métricas Clave: Soporte y Confianza

Un algoritmo puede generar miles de reglas inútiles. Usamos dos métricas probabilísticas para filtrarlas:



Fórmulas: Soporte y Confianza

Soporte (Support)

Indica la frecuencia o relevancia global de la regla. ¿Qué porcentaje de TODAS las transacciones en la tienda contienen tanto A como B?

$$\text{Support}(A \rightarrow B) = P(A \cap B) = \frac{\text{Freq}(A, B)}{N}$$

Confianza (Confidence)

Indica la fiabilidad de la regla. De todas las veces que alguien compró A, ¿cuántas veces también compró B?

$$\text{Confidence}(A \rightarrow B) = P(B|A) = \frac{\text{Support}(A \cup B)}{\text{Support}(A)} = \frac{\text{Freq}(A, B)}{\text{Freq}(A)}$$


El Problema Exponencial de Búsqueda

Si una tienda de autoservicio tiene 10,000 productos distintos, el número de combinaciones posibles para crear reglas de asociación crece exponencialmente ($2^d - 1$). Es matemáticamente imposible que una computadora verifique la frecuencia de todas las combinaciones posibles.

La Solución: El Algoritmo Apriori. Apriori es un algoritmo pionero propuesto por Agrawal y Srikant para minar *itemsets* (conjuntos de artículos) frecuentes utilizando conocimiento previo.

La Propiedad Apriori (Cierre Hacia Abajo)

El algoritmo se basa en una premisa de anti-monotonidad: **"Si un conjunto de artículos es frecuente, todos sus subconjuntos también deben ser frecuentes."**



Lógica: Si $\{A, B\}$ es clasificado como INFRECIENTE, matemáticamente $\{A, B, C\}$ jamás podrá ser frecuente, por lo que lo podemos y evitamos calcularlo. Esto ahorra millones de operaciones.

Ejemplo Algoritmo Apriori (1/4)

Base de Datos Transaccional ($N = 4$)

- $T1$: {Pan, Leche, Pañales}
- $T2$: {Pan, Pañales, Cerveza, Huevos}
- $T3$: {Leche, Pañales, Cerveza}
- $T4$: {Pan, Leche, Pañales, Cerveza}

Parámetros Mínimos:

- Soporte Mínimo (Min_Sup) = 50 % (Es decir, debe aparecer en al menos 2 transacciones).
- Confianza Mínima (Min_Conf) = 75 %.

Ejemplo Algoritmo Apriori (2/4)

Iteración 1: Encontrar los 1-Itemsets frecuentes (L_1)

1. Escaneamos la base de datos para contar frecuencias individuales (Candidatos C_1):
 - Pan: 3 Leche: 3 Pañales: 4 Cerveza: 3 Huevos: 1
2. Aplicamos la poda (Pruning) eliminando los que no cumplen el $\text{Min_Sup} \geq 2$:

Poda de C_1

Se elimina {Huevos} porque su soporte es 1 (menor a 2).

Lista Frecuente L_1 : {Pan} (3), {Leche} (3), {Pañales} (4), {Cerveza} (3).

Ejemplo Algoritmo Apriori (3/4)

Iteración 2: Encontrar los 2-Itemsets frecuentes (L_2)

1. Combinamos (Join) los elementos de L_1 para generar pares (C_2) y los contamos:

- {Pan, Leche}: 2
- {Pan, Pañales}: 3
- {Pan, Cerveza}: 2
- {Leche, Pañales}: 3
- {Leche, Cerveza}: 2
- {Pañales, Cerveza}: 3

2. Aplicamos la poda: En este caso, todos los pares tienen una frecuencia de al menos 2. Todos sobreviven y pasan a conformar la lista L_2 .

Ejemplo Generación de Reglas (4/4)

Tomemos el par frecuente **{Pan, Pañales}** de L_2 (Aparece 3 veces). Puede generar dos reglas. Evaluemos si cumplen la $Min_Conf \geq 75\%$:

Regla 1: Pan $\rightarrow$ Pañales

$$Confidence = \frac{Freq(Pan \cap Pañales)}{Freq(Pan)}$$

$$Confidence = \frac{3}{3} = \mathbf{1,0 \text{ (100\%)}}$$

Dado que $100\% \geq 75\%$, esta **SÍ es una Regla Fuerte**.

Regla 2: Pañales $\rightarrow$ Pan

$$Confidence = \frac{Freq(Pan \cap Pañales)}{Freq(Pañales)}$$

$$Confidence = \frac{3}{4} = \mathbf{0,75 \text{ (75\%)}}$$

Dado que $75\% \geq 75\%$, esta también es una **Regla Fuerte** que retiene el sistema.

La Trampa de la Confianza: Introducción al LIFT

Si una tienda regala bolsas de plástico con cada compra, la regla "*Si compras Leche $\rightarrow$ Llevas Bolsa de plástico*" tendrá una Confianza del 99 %. ¿Es esto útil? No.

La confianza falla cuando el consecuente (B) es inmensamente popular por sí solo. Necesitamos el **Lift** (**Elevación o Sustento**).

Fórmula del Lift

Mide cuántas veces es más probable que A y B se compren juntos en comparación a lo esperado si fueran variables estadísticamente independientes.

$$Lift(A \rightarrow B) = \frac{Confidence(A \rightarrow B)}{Support(B)} = \frac{P(B|A)}{P(B)}$$

- **Lift = 1**: A y B son independientes.
- **Lift > 1**: Hay una relación de atracción real.
- **Lift < 1**: Hay una relación de repulsión (Si compro A , es menos probable que compre B).

Ejercicio 2: Métricas de Reglas de Asociación

Dataset de Compras de 10 Clientes ($N = 10$):

- 6 clientes compraron *Videojuegos*.
- 8 clientes compraron *Refresco*.
- 5 clientes compraron **ambos** (*Videojuegos* y *Refresco*).

Para la regla sugerida por el algoritmo: *Videojuegos* $\rightarrow$ *Refresco*

Instrucciones:

1. Calcula el **Soporte** de la regla.
2. Calcula la **Confianza** de la regla.
3. Calcula el **Lift** de la regla e indica si la regla es realmente útil (atracción real) o si la alta confianza es una ilusión producida por la enorme popularidad general de los refrescos.

(Tienen 5 minutos. Desarrollen las fórmulas en su cuaderno).

Solución al Ejercicio 2

$N = 10$, $Freq(V) = 6$, $Freq(R) = 8$, $Freq(V, R) = 5$.

1. Soporte de la Regla ($V \rightarrow R$):

$$Support = \frac{Freq(V \cap R)}{N} = \frac{5}{10} = \mathbf{0,50 \text{ (50\%)}}$$

2. Confianza de la Regla ($V \rightarrow R$):

$$Confidence = \frac{Freq(V \cap R)}{Freq(V)} = \frac{5}{6} = \mathbf{0,833 \text{ (83,3\%)}}$$

3. Lift de la Regla ($V \rightarrow R$):

$$Lift = \frac{Confidence(V \rightarrow R)}{Support(R)}$$
$$Lift = \frac{0,833}{8/10} = \frac{0,833}{0,80} = \mathbf{1,04}$$

Conclusión: Un Lift de 1.04 está casi en 1. Aunque la Confianza es alta (83.3%), el Lift nos revela que comprar videojuegos tiene un impacto **mínimo y casi nulo** sobre la probabilidad natural (80%) de comprar un refresco.

Resumen de la Sesión

- Comenzamos la **Fase de Modelado** analizando cómo los datos procesados son convertidos en conocimiento.
- Los **Métodos Estadísticos** confían en la Correlación de Pearson para depurar variables y en el Teorema de Bayes para asignar probabilidades directas de clasificación, basándose en la independencia condicional.
- El minado de patrones frecuentes produce **Reglas de Asociación**.
- El **Algoritmo Apriori** hace factible esta búsqueda exponencial podando tempranamente las ramas de combinaciones infrecuentes.
- Para validar asociaciones usamos el **Soporte** y la **Confianza**, pero sin el **Lift**, corremos el riesgo de ser engañados por atributos globalmente hiper-frecuentes.

Referencias Bibliográficas

- Han, J., Pei, J., & Tong, H. (2022). *Data Mining: Concepts and Techniques* (4th ed.). Morgan Kaufmann. (Capítulo 5: Mining Frequent Patterns, Associations, and Correlations).
- Larose, D. T., & Larose, C. D. (2015). *Data Mining and Predictive Analytics* (2nd ed.). Wiley. (Capítulo 14: Naïve Bayes and Bayesian Networks, Capítulo 23: Association Rules).
- Programa Sintético de Estudios: Unidad Temática III (Técnicas de Minería de Datos). IPN.

¿Preguntas o Comentarios?

Fin de la presentación

Anexo: Limitaciones de Naïve Bayes

Aunque Naïve Bayes es computacionalmente muy veloz y requiere poca memoria, su principal debilidad radica en su premisa de **Independencia Condicional**.

El problema de la "Probabilidad Cero": Si un valor de atributo en el conjunto de pruebas jamás ocurrió junto a una clase en el conjunto de entrenamiento (ej. un Tumor Maligno y un valor de textura "Suave"), su probabilidad condicional $P(\text{Suave}|M)$ será cero.

Dado que las probabilidades se multiplican, este único cero **anulará** completamente la probabilidad final de toda la ecuación a posteriori.

Solución estándar: Emplear la corrección de Laplace (sumar 1 a todos los conteos de frecuencia para evitar el cero matemático).

Anexo: Formato Transaccional de Datos

A diferencia de los DataFrames tradicionales con formato relacional, las Reglas de Asociación en Apriori exigen a menudo una estructuración de datos especializada.

Representación Horizontal: Una fila por transacción (TID), con una lista variable de los IDs de los artículos comprados. (Excelente almacenamiento para canastas de supermercado dispersas).

Representación Binaria/Dummy: Matriz de tamaño ($N \times M$ artículos). Las columnas son artículos, y contienen 1 o 0 indicando presencia. Permite cálculos vectorizados de soporte usando álgebra matricial (producto cruzado), que es la base de las implementaciones vectorizadas rápidas de Apriori en lenguajes como R o Python.