

Técnicas Avanzadas de Minería de Datos

Máquinas de Vectores de Soporte (SVM): Márgenes y Kernels

Ingeniería en Inteligencia Artificial

Instituto Politécnico Nacional

Daniel Sánchez Ruiz

Agenda de la Sesión

1. Reemplazando Árboles y Redes: Nuevos Enfoques
2. Fundamentos de SVM y Separación Lineal
3. Desarrollo Matemático de SVM
4. Soft Margin: Manejando Datos Ruidosos
5. No Linealidad y el Truco del Kernel
6. Ejercicio Práctico y Solución
7. Conclusiones y Próximos Pasos

Evolución de las Técnicas de Modelado

Dado que los algoritmos clásicos como los Árboles de Decisión y las Redes Neuronales han sido cubiertos en asignaturas previas, en esta unidad exploraremos dos técnicas de nivel superior que dominan el aprendizaje automático clásico:

- ➊ **Máquinas de Vectores de Soporte (SVM):** Un enfoque matemáticamente riguroso basado en la maximización de márgenes geométricos y la transformación de dimensionalidad.
- ➋ **Métodos de Ensamble (Bagging y Boosting):** Algoritmos que combinan múltiples clasificadores débiles para formar un modelo robusto (ej. Random Forest, AdaBoost, XGBoost).

Hoy dedicaremos la sesión a desentrañar la matemática y la intuición geométrica detrás de SVM.

¿Qué es una Máquina de Vectores de Soporte (SVM)?

Las Máquinas de Vectores de Soporte (SVM) son algoritmos de aprendizaje supervisado utilizados para clasificación y regresión.


Objetivo Principal

El objetivo de SVM es encontrar un **hiperplano** en un espacio de N dimensiones (donde N es el número de características) que separe de manera óptima los puntos de datos de diferentes clases.

A diferencia de métodos estadísticos simples que solo buscan *una* línea que separe los datos, SVM busca la línea que deje el **mayor margen posible** entre las clases, lo que garantiza una mejor generalización sobre datos no vistos.

El Problema: Infinitas Soluciones Posibles

Para un conjunto de datos linealmente separable, existen infinitos hiperplanos (líneas en 2D) que pueden dividir las clases con cero errores en el entrenamiento.




¿Cuál de estas fronteras de decisión (H_1, H_2, H_3) es la mejor? Un perceptrón clásico se detendría al encontrar cualquiera de ellas.

La Solución SVM: El Margen Máximo

SVM introduce el concepto de **Margen Máximo**. Intuitivamente, la mejor frontera de decisión es aquella que está lo más lejos posible de los puntos de datos más cercanos de ambas clases.

- **Hiperplano:** La frontera de decisión en sí.
- **Vectores de Soporte:** Son los puntos de datos críticos que están más cerca del hiperplano. Si estos puntos se eliminan, la posición del hiperplano divisorio cambiaría. ¡Son los únicos puntos que importan para definir el modelo!
- **Margen:** Es la distancia perpendicular desde el hiperplano hasta los vectores de soporte más cercanos.

Anatomía de SVM (Representación Visual)



Desarrollo Matemático: Ecuación del Hiperplano

Dado un conjunto de entrenamiento con m muestras: $(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)$, donde $\mathbf{x}_i \in \mathbb{R}^n$ representa las características y $y_i \in \{-1, +1\}$ son las etiquetas de clase.

Cualquier hiperplano puede definirse como el conjunto de puntos $\mathbf{x}$ que satisfacen:

Ecuación del Hiperplano

$$\mathbf{w}^T \mathbf{x} + b = 0$$

Donde:

- $\mathbf{w}$ es el vector de pesos (weight vector), que es normal (perpendicular) al hiperplano.
- b es el sesgo (bias), que desplaza el hiperplano respecto al origen.

Desarrollo Matemático: Las Restricciones Lineales

Queremos que nuestras predicciones sean correctas y que caigan *fuera* de la zona de margen. Establecemos matemáticamente dos hiperplanos paralelos de margen:

Para la clase positiva ($y_i = +1$):

$$\mathbf{w}^T \mathbf{x}_i + b \geq 1$$

Para la clase negativa ($y_i = -1$):

$$\mathbf{w}^T \mathbf{x}_i + b \leq -1$$

Podemos condensar ambas restricciones en una sola inecuación elegante multiplicando por y_i :

Restricción Unificada

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \forall i \in \{1, \dots, m\}$$

Desarrollo Matemático: El Tamaño del Margen

La distancia desde el hiperplano central $\mathbf{w}^T \mathbf{x} + b = 0$ hasta cualquier punto $\mathbf{x}$ está dada por:

$$\text{Distancia} = \frac{|\mathbf{w}^T \mathbf{x} + b|}{\|\mathbf{w}\|}$$

Para los **Vectores de Soporte** (los puntos que caen exactamente sobre los planos de margen discontinuos vistos en el gráfico), sabemos que $|\mathbf{w}^T \mathbf{x} + b| = 1$.

Por lo tanto, la distancia desde el hiperplano central a un vector de soporte es $\frac{1}{\|\mathbf{w}\|}$. Como el margen total abarca ambos lados (clase positiva y negativa), el ancho total del margen es:

Ancho del Margen

$$\text{Margen Total} = \frac{2}{\|\mathbf{w}\|}$$

Desarrollo Matemático: El Problema de Optimización

El objetivo principal de SVM es **Maximizar el Margen**, es decir, maximizar $\frac{2}{\|\mathbf{w}\|}$.

Matemáticamente, maximizar $\frac{2}{\|\mathbf{w}\|}$ es equivalente a **minimizar** $\frac{1}{2}\|\mathbf{w}\|^2$. El uso del cuadrado y la fracción $\frac{1}{2}$ es un truco matemático que hace que la función objetivo sea convexa y su derivada sea simplemente $\mathbf{w}$.

Problema de Optimización Primario (Hard Margin)

Minimizar:

$$J(\mathbf{w}) = \frac{1}{2}\|\mathbf{w}\|^2$$

Sujeto a:

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \forall i$$

Este es un problema clásico de Programación Cuadrática con restricciones lineales.

Resolución: Multiplicadores de Lagrange

Para resolver esta optimización con restricciones, se introduce el método de los **Multiplicadores de Lagrange** (α_i).

Construimos el Lagrangiano:

$$\mathcal{L}(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i [y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

Derivando respecto a $\mathbf{w}$ y b e igualando a cero, descubrimos que el vector de pesos óptimo $\mathbf{w}$ es una combinación lineal de los vectores de soporte:

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i$$

Nota crucial: Para la gran mayoría de los puntos de datos, $\alpha_i = 0$. Los únicos puntos con $\alpha_i > 0$ son los Vectores de Soporte.

Cuando la Separación Perfecta Falla

El modelo matemático anterior asume que los datos son **estrictamente separables de forma lineal**. A esto se le conoce como *Hard Margin SVM*.

¿Qué sucede en el mundo real?

- Los datos suelen contener **ruido** o **valores atípicos** (outliers).
- Un solo outlier de la clase roja metido profundamente en el territorio azul haría que el optimizador de *Hard Margin* no encuentre ninguna solución (el margen colapsaría).

Para resolver esto, Cortes y Vapnik introdujeron en 1995 el concepto de **Margen Suave (Soft Margin)** [8, 9].

Matemáticas del Soft Margin: Variables de Holgura (ξ_i)

Se introducen **variables de holgura (slack variables)** $\xi_i \geq 0$ para cada punto de datos. Estas variables permiten que algunos puntos violen la restricción del margen.

La nueva restricción pasa a ser:

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$

- Si $\xi_i = 0$, el punto está clasificado correctamente y fuera del margen.
- Si $0 < \xi_i < 1$, el punto cae dentro del margen, pero en el lado correcto.
- Si $\xi_i > 1$, el punto cae en el lado incorrecto del hiperplano (error de clasificación).

La Nueva Función Objetivo y el Parámetro C

Al permitir violaciones, debemos penalizarlas en la función objetivo. Introducimos el hiperparámetro **C** (Costo).

Optimización con Margen Suave

Minimizar:


$$J(\mathbf{w}, \xi) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$$

Interpretación de C (Bias-Variance Tradeoff):

- **C grande:** Fuerte penalización por errores. El margen será muy estrecho para intentar clasificar todo bien. Riesgo de *sobreajuste* (overfitting).
- **C pequeño:** Penalización leve. Permite más errores a cambio de un margen más ancho. Mayor *generalización*.

Limitación de SVM Lineal

Incluso con márgenes suaves, SVM es fundamentalmente un clasificador lineal. ¿Qué ocurre si los datos tienen un límite de decisión inherentemente no lineal, como el clásico problema XOR o datos concéntricos?




Ninguna línea recta en este espacio 2D puede separar los puntos azules de los rojos.

La Solución: Proyección a Alta Dimensionalidad (ϕ)

La idea brillante de SVM para datos no lineales es mapear las características originales a un espacio de dimensiones superiores donde los datos *sí* sean linealmente separables [4].

Ejemplo: Mapear datos 2D (x_1, x_2) a 3D $(x_1, x_2, x_1^2 + x_2^2)$.



El "Truco del Kernel" (Kernel Trick)

Mapear datos a un espacio de dimensiones altísimas (o infinitas) es computacionalmente imposible de calcular punto por punto.

Sin embargo, al resolver el problema dual de SVM, las observaciones de datos siempre aparecen emparejadas en forma de un **producto punto**: $\phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$.

El Truco del Kernel

Podemos reemplazar el producto punto en el espacio transformado por una **función Kernel** $K(\mathbf{x}_i, \mathbf{x}_j)$ que calcula este producto directamente en el espacio original sin tener que realizar nunca la costosa transformación ϕ .

$$K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$

Funciones Kernel más Comunes

La elección del kernel define el tipo de límite de decisión que el modelo puede aprender [10]:

① **Lineal:** $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$

Útil cuando el número de características es muy alto (ej. Clasificación de texto).

② **Polinomial:** $K(\mathbf{x}_i, \mathbf{x}_j) = (\gamma \mathbf{x}_i^T \mathbf{x}_j + r)^d$

Útil en procesamiento de imágenes. d es el grado del polinomio.

③ **RBF (Función de Base Radial / Gaussiana):** $K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$

Mapea los datos a un espacio de dimensionalidad infinita. Es el kernel por defecto más poderoso en herramientas como `scikit-learn`.

④ **Sigmoide:** $K(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\gamma \mathbf{x}_i^T \mathbf{x}_j + r)$

Históricamente usado como proxy para redes neuronales.

Clasificación Multi-clase y Regresión (SVR)

Clasificación Multi-clase: Originalmente, SVM es un clasificador estrictamente binario. Para K clases, se usan dos estrategias:

- **Uno-contra-Todos (One-vs-Rest, OVR):** Entrena K clasificadores (Clase A vs No-A).
- **Uno-contra-Uno (One-vs-One, OVO):** Entrena $\frac{K(K-1)}{2}$ clasificadores (cada par posible).

Support Vector Regression (SVR): SVM se puede adaptar para predecir números continuos [11]. La regresión SVR crea un "tubo" (margen ϵ) alrededor de la función predicha y penaliza solo los puntos que caen *fuera* de este tubo, ignorando los errores menores a ϵ .

Ventajas y Desventajas de SVM

Ventajas

- Excelente capacidad predictiva y generalización gracias a la maximización del margen.
- Efectivo en espacios de muy alta dimensión (incluso donde $N_{\text{características}} > M_{\text{muestras}}$).
- Eficiencia de memoria: la fase de predicción solo requiere guardar los Vectores de Soporte en RAM.
- Versátil gracias a distintos Kernels [10].

Desventajas

- Tiempo de entrenamiento excesivo en conjuntos de datos enormes (big data). Escala a $O(N^3)$ en implementaciones estándar.
- No proporciona estimaciones probabilísticas de forma directa (como la Regresión Logística o Naïve Bayes).
- Sensible a la escala de las características (es obligatorio normalizar/estandarizar los datos previamente).

Ejercicio Práctico para los Alumnos

Problema Geométrico de SVM

Un algoritmo de SVM lineal ha procesado un conjunto de datos 2D y ha extraído la siguiente ecuación para el hiperplano óptimo:

$$\mathbf{w}^T \mathbf{x} + b = 0 \quad \text{donde} \quad \mathbf{w} = \begin{pmatrix} 2 \\ -1 \end{pmatrix} \quad \text{y} \quad b = -3$$

Instrucciones:

1. Calcula el tamaño total del **Margen Máximo** geométrico entre las dos clases.
2. Tienes tres nuevos pacientes con las siguientes coordenadas (x_1, x_2) :
 - Paciente A: $(3, 1)$
 - Paciente B: $(1, -2)$
 - Paciente C: $(2, 1)$

Predice la clase $(+1$ o $-1)$ para cada paciente e indica si el Paciente C se encuentra dentro de la "zona de margen" de clasificación.

Solución al Ejercicio (Paso 1: Margen)

1. Cálculo del Margen Máximo

Conocemos la fórmula del margen total de SVM:

$$\text{Margen Total} = \frac{2}{\|\mathbf{w}\|}$$

Donde $\mathbf{w} = \begin{pmatrix} 2 \\ -1 \end{pmatrix}$. Primero, calculamos la norma Euclídea del vector de pesos:

$$\|\mathbf{w}\| = \sqrt{w_1^2 + w_2^2}$$

$$\|\mathbf{w}\| = \sqrt{2^2 + (-1)^2}$$

$$\|\mathbf{w}\| = \sqrt{4 + 1} = \sqrt{5} \approx 2,236$$

Por lo tanto, el margen es:

$$\text{Margen Total} = \frac{2}{\sqrt{5}} \approx \mathbf{0,894} \text{ unidades}$$

Solución al Ejercicio (Paso 2: Predicción)

2. Predicción de las Nuevas Muestras La regla de decisión es calcular el valor escalar $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$. Si $f(\mathbf{x}) \geq 0$, la clase es $+1$; si $f(\mathbf{x}) < 0$, la clase es -1 .

Paciente A (3, 1):

$$f(A) = (2)(3) + (-1)(1) - 3 = 6 - 1 - 3 = 2$$

→ Clase predictiva: **+1** (Está fuera del margen porque $2 \geq 1$).

Paciente B (1, -2):

$$f(B) = (2)(1) + (-1)(-2) - 3 = 2 + 2 - 3 = 1$$

→ Clase predictiva: **+1** (Es de hecho un Vector de Soporte porque su valor es exactamente 1).

Paciente C (2, 1):

$$f(C) = (2)(2) + (-1)(1) - 3 = 4 - 1 - 3 = 0$$

→ **Precaución:** Está cayendo exactamente sobre el hiperplano central. La predicción probabilística es indecisa, cae de lleno en el centro de la zona de margen. En la práctica algorítmica, se le asigna $+1$ o se clasifica como límite.

- Las Máquinas de Vectores de Soporte (SVM) sustituyen heurísticas simples con una base matemática sólida que garantiza una generalización óptima mediante la **maximización del margen geométrico**.
- El modelo completo está definido exclusivamente por un puñado de puntos críticos llamados **Vectores de Soporte**.
- El **Soft Margin (Parámetro C)** permite que el algoritmo tolere ruido y outliers sin corromper el modelo.
- El verdadero poder de SVM en el contexto moderno del Big Data es el **Kernel Trick** (ej. Kernel RBF o Gaussiano), que permite modelar fronteras de decisión altamente no-lineales proyectando la información a hiperespacios matemáticos de forma eficiente.

Referencias Bibliográficas

- Han, J., Pei, J., & Tong, H. (2022). *Data Mining: Concepts and Techniques* (4th ed.). Morgan Kaufmann. (Capítulo 7: Support Vector Machines).
- Larose, D. T., & Larose, C. D. (2015). *Data Mining and Predictive Analytics* (2nd ed.). Wiley.
- Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297.
- Yu, C.H. (2022). *Data Mining and Exploration: From Traditional Statistics to Modern Data Science*. CRC Press. (Introducción a Kernels y Clasificadores Modernos).