



REDES NEURONALES Y APRENDIZAJE PROFUNDO

Nombres: MACIAS MONDRAGON RODOLFO, REYES CRUZ ROBERTO MISAEAL

Especialidad: Inteligencia Artificial

Fecha de la práctica: 5 de marzo de 2026

Práctica: Identificación de Idioma mediante Red Neuronal

Objetivo:

Implementar el preprocesamiento de datos que permita calcular la frecuencia de aparición de las letras de un texto y luego entrenar y probar una red neuronal de forma que permita identificar el idioma de un texto.

Instrucciones: Asegúrate de escribir código limpio y comentado. Al final de cada sección, responde a las preguntas de reflexión para reforzar tu comprensión del proceso.

Parte 1: Preparación de datos

Escribe una función que tome un texto y calcule la frecuencia de cada letra del abecedario. Esta función normaliza las frecuencias de las letras en relación con la longitud del texto.

Función: void frequencies(char* text, float* frequencies);

Entradas:

text: La cadena de caracteres representando el texto.

frequencies: Un arreglo de flotantes de tamaño 27 donde almacenar las frecuencias de las letras (26 letras + 1 para otros caracteres).

Parte 2: Datos de entrenamiento y prueba

Utiliza la función frequencies para generar vectores de frecuencia para textos en tres idiomas diferentes: español, inglés y francés.

- Prepara al menos 10 textos para cada idioma en archivos separados, cada texto no deberá ser mayor a 500 letras.
- Genera y almacena los vectores de frecuencia y las etiquetas correspondientes.

Ejemplo de textos:

- Español: "La inteligencia artificial ha revolucionado muchos aspectos de nuestras vidas cotidianas. Desde la asistencia en tareas rutinarias hasta el avance en la investigación científica, la tecnología está transformando el mundo. Es fundamental adaptarse a estos cambios y aprender a utilizar las herramientas digitales de manera eficaz."
- Inglés: "Artificial intelligence has revolutionized many aspects of our daily lives. From assisting with routine tasks to advancing scientific research, technology is transforming the world. It is essential to adapt to these changes and learn how to use digital tools effectively to stay competitive in today's fast-paced environment."

- Francés: "L'intelligence artificielle a révolutionné de nombreux aspects de notre vie quotidienne. De l'assistance aux tâches routinières à l'avancement de la recherche scientifique, la technologie transforme le monde. Il est essentiel de s'adapter à ces changements et d'apprendre à utiliser efficacement les outils numériques pour rester compétitif."

Parte 3: Entrenamiento de la red neuronal

Realiza una implementación de una red neuronal con backpropagation. Tu tarea es entrenar la red neuronal con los datos de entrenamiento. Para ello es necesario presentar los datos de entrada a la red, invocar a la función `forward_propagate` y posteriormente realizar el ajuste de los pesos con la función `backpropagate`. Es importante adecuar el programa dado para que sea posible observar el error en pantalla durante el proceso de entrenamiento.

Parte 4: Prueba de la red neuronal

Realiza una implementación de una red neuronal con backpropagation. Tu tarea es entrenar la red neuronal con los datos de entrenamiento. Para ello es necesario presentar los datos de entrada a la red, invocar a la función `forward_propagate` y posteriormente realizar el ajuste de los pesos con la función `backpropagate`. Es importante adecuar el programa dado para que sea posible observar el error en pantalla durante el proceso de entrenamiento.

Preguntas de reflexión

- ¿Por qué es importante normalizar la frecuencia de las letras en relación con la longitud del texto?
- ¿Cómo manejarías textos con caracteres especiales o acentos? ¿Deberían incluirse en el cálculo de frecuencia o no?
- ¿Cómo afecta la longitud del texto a la precisión del cálculo de las frecuencias?
- ¿Es suficiente el número de textos por idioma? ¿Por qué si o por qué no?
- ¿Qué criterios utilizarías para seleccionar la tasa de aprendizaje y el número de épocas de entrenamiento?
- ¿Qué diferencias observas en la salida de la red neuronal para los diferentes textos de prueba?
- ¿Cómo podrías mejorar el preprocesamiento de los datos para mejorar la precisión de la red?

Entrega:

La entrega consistirá en un documento explicativo que contenga una breve introducción, presente evidencias de ejecución del programa, las preguntas de reflexión, sus respuestas y una conclusión adecuada para el trabajo realizado. En formato pdf. Es importante mencionar que las evidencias de ejecución durante el entrenamiento y la prueba deben estar explicadas.

Además, entregar el programa y que permita entrenar y probar la red neuronal, junto con los archivos de entrenamiento y los archivos de prueba del programa.

Introducción:

El desarrollo de la práctica busca crear una Red Neuronal Multicapa (MLP) capaz de identificar el idioma de un texto, determinando si este pertenece al español, inglés o francés. La clasificación se basa en la frecuencia de aparición de las letras del abecedario, más un carácter adicional.

Evidencias:

Como primera evidencia del programa, al ver la Figura 1, podemos observar que el programa entrenó 1000 épocas, la tasa de aprendizaje fue de $c=0.5$

```
... Época 1: Error=11.422215
    Época 2: Error=11.102389
    Época 3: Error=11.093581
    Época 4: Error=11.080110
    Época 5: Error=11.066547
    Época 6: Error=11.053010
    Época 7: Error=11.039501
    Época 8: Error=11.026017
    Época 9: Error=11.012558
    Época 10: Error=10.999119
    Época 11: Error=10.985701
    Época 12: Error=10.972299
    Época 13: Error=10.958912
    Época 14: Error=10.945537
    Época 15: Error=10.932172
    Época 16: Error=10.918813
    Época 17: Error=10.905459
    Época 18: Error=10.892106
    Época 19: Error=10.878752
    Época 20: Error=10.865393
    Época 21: Error=10.852026
    Época 22: Error=10.838649
    Época 23: Error=10.825257
    Época 24: Error=10.811848
    Época 25: Error=10.798418
    ...
    Época 997: Error=0.147010
    Época 998: Error=0.146683
    Época 999: Error=0.146356
    Época 1000: Error=0.146031
    Output is truncated. View as a scrollable element or d
```

Figura 1. Vemos como actúa el descenso de gradiente disminuyendo el error.

En la Figura 2 podemos observar la prueba del modelo al presentarle nuevos textos. La codificación one-hot quedó definida como [english, spanish, french]. Este vector representa la probabilidad asignada a cada idioma. Con base en estas probabilidades, se selecciona el valor mayor para determinar a qué idioma pertenece el texto, y posteriormente se verifica si la predicción fue correcta o no.

```

[14] ✓ 0.05
... Archivo: spanish_2.txt
Probabilidades: [0.00553901 0.94133936 0.09975074]
Prediccion: spanish
Correcto

Archivo: french_2.txt
Probabilidades: [0.00967435 0.05912571 0.93188418]
Prediccion: french
Correcto

Archivo: french_t3.txt
Probabilidades: [0.05897262 0.00537234 0.94713824]
Prediccion: french
Correcto

Archivo: french_3.txt
Probabilidades: [0.05897262 0.00537234 0.94713824]
Prediccion: french
Correcto

Archivo: english_t1.txt
Probabilidades: [0.98071534 0.00806666 0.0048272 ]
Prediccion: english
Correcto
...
Prediccion: english
Correcto

Precision final: 100.00%
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell ou

```

Figura 2. Desglose de la prueba de la Red Neuronal a diferentes textos.

Preguntas de reflexión

- ¿Por qué es importante normalizar la frecuencia de las letras en relación con la longitud del texto? Es importante porque textos más largos generan mayores conteos de letras, lo que podría introducir un sesgo en el entrenamiento en base a la longitud. Si no se normaliza, la red aprendería diferencias basadas en la cantidad de caracteres y no en la distribución real de las letras.
- ¿Cómo manejarías textos con caracteres especiales o acentos? ¿Deberían incluirse en el cálculo de frecuencia o no? Hay dos enfoques que se pueden tratar, una es asignarlos a una categoría especial, o estandarizar todas las letras eliminándolas (por ejemplo, á en a y así sucesivamente). Se deberían incluir en el cálculo dependiendo de que tanto se quiera aumentar la precisión y complejidad al modelo.
- ¿Cómo afecta la longitud del texto a la precisión del cálculo de las frecuencias? Representa mejor la distribución de letras del idioma. En textos muy cortos, la frecuencia puede variar mucho por azar y no reflejar realmente el patrón lingüístico.

- ¿Es suficiente el número de textos por idioma? ¿Por qué si o por qué no? Para los objetivos de esta práctica, el número de textos fue suficiente, ya que permitió que la red aprendiera patrones básicos y lograr buena precisión en la prueba. Pero ya en un contexto mas robusto, 10 textos por idioma es una cantidad (muy) pequeña. En problemas reales, se necesitarían muchos más ejemplos para asegurar una buena capacidad de generalización y evitar sobreajuste.
- ¿Qué criterios utilizarías para seleccionar la tasa de aprendizaje y el número de épocas de entrenamiento? La tasa de aprendizaje debe elegirse de manera que permita una disminución progresiva del error sin que este diverja. Si es muy alta, el entrenamiento puede volverse inestable; si es muy baja, el aprendizaje será demasiado lento. El número de épocas debe ser suficiente para que el error converja, pero no tan grande que cause sobreajuste.
- ¿Qué diferencias observas en la salida de la red neuronal para los diferentes textos de prueba? Los textos muy representativos de cada idioma generan una probabilidad claramente dominante en una de las tres salidas. En algunos casos, cuando el texto comparte características con otro idioma (español, francés), las probabilidades pueden estar más cercanas entre sí.
- ¿Cómo podrías mejorar el preprocesamiento de los datos para mejorar la precisión de la red?
 - o Normalizar acentos para unificar letras equivalentes. (Para español, francés)
 - o Eliminar signos de puntuación.
 - o Incluir n-gramas en lugar de frecuencias individuales.
 - o Aumentar el número de textos por idioma.

Estas mejoras permitirían capturar patrones lingüísticos más complejos y aumentar la capacidad discriminativa del modelo.

Conclusiones

En esta práctica se logró implementar una Red Neuronal Multicapa capaz de identificar el idioma de un texto a partir de la frecuencia de sus letras. El trabajo permitió comprender de manera práctica el funcionamiento del entrenamiento con backpropagation y la importancia de los parámetros del modelo en la precisión final. Al igual que la experimentación de parametros.

